

Relatório Técnico: Construção e Avaliação da Baseline do Agente de Monitoramento e Previsão de Evasão

Unidade Curricular: Inteligência Artificial e Aprendizado de Máquina

1. Visão Geral e Contexto

Este relatório técnico documenta a construção, o pré-processamento de dados e a avaliação de modelos de *baseline* para o Agente de Monitoramento acadêmico e financeiro. O objetivo central é prever a evasão de alunos (**churn** / cancelamento de matrícula) com base em dados unificados de contato, histórico escolar, situação financeira e dados cadastrais, permitindo que o agente atue proativamente na retenção estudantil.

2. Análise de Dados e Preparação

A base unificada (base_unificada_asa-final.csv) contém **12.842 registros e 24 colunas**, sem valores ausentes (*missing values*), estruturada em nível de aluno.

- **Seleção de Atributos:**

- *Identificadores*: A coluna ID_ALUNO foi removida por atuar apenas como chave primária sem poder preditivo.
- *Alvo (Target)*: evadiu (variável binária: 0 para permanência, 1 para evasão).
- *Variáveis Numéricas e Categóricas*: Foram mantidas variáveis comportamentais e acadêmicas (ex: notas médias, atrasos financeiros, percentual de parcelas em aberto) e categóricas demográficas/acadêmicas (ex: Grau Acadêmico, Turno, Forma de Ingresso, Estado Civil, Sexo).

- **Engenharia de Atributos e Transformação:**

- Conversão da coluna booleana tem_bolsa para formato numérico inteiro.
- Aplicação de *One-Hot Encoding* nas variáveis categóricas, expandindo o espaço de características para capturar correlações não lineares.
- Divisão estratificada dos dados em **80% para treino e 20% para teste**, preservando a proporção original da classe alvo.
- Padronização das escalas (*StandardScaler*) aplicada para modelos sensíveis à magnitude das features (Regressão Logística e KNN).

3. Métricas de Avaliação

Como o problema envolve predição de risco de evasão, o desempenho dos modelos foi medido através de:

- **Acurácia:** Taxa global de acertos do modelo.
- **F1-Score (Ponderado):** Média harmônica entre precisão e revocação, ideal para mitigar o impacto de possíveis desbalanceamentos.
- **ROC-AUC:** Capacidade do modelo de discriminar entre alunos evadidos e não evadidos em diferentes limiares de decisão.

4. Monitoramento e Resultados da Baseline Inicial

Quatro algoritmos distintos foram testados para estabelecer a linha de base (*baseline*):

Modelo	Acurácia	F1-Score (Ponderado)	ROC-AUC	Observações / Fatores Explicativos
Regressão Logística	0.8451	0.8410	0.8842	Baseline linear estável, útil para interpretação direta dos coeficientes de risco.
KNN (K-Nearest Neighbors)	0.8404	0.8352	0.8510	Sensível à escala, apresentou desempenho competitivo baseado na proximidade dos perfis.
Árvore de Decisão	0.8715	0.8690	0.8320	Alta interpretabilidade visual, permitindo extrair regras lógicas diretas para o agente.
Random	0.9093	0.9065	0.9321	Melhor

Forest				baseline geral, reduzindo variância e capturando interações complexas entre atrasos financeiros e histórico acadêmico.
---------------	--	--	--	--

Model Card: Agente de Monitoramento e Previsão de Evasão (v1.0)

Descrição do Modelo

- **Nome:** Baseline Evasion Monitor Agent (BEMA)
- **Versão:** 1.0
- **Tipo de Modelo:** Classificador Ensemble baseado em Random Forest (com benchmarks de Regressão Logística, Árvore de Decisão e KNN).
- **Desenvolvedor:** Equipe do Projeto Integrador / Agente de Monitoramento.
- **Data da Versão:** Setembro de 2026.

Intenção de Uso

- **Uso Primário:** Identificar de forma preditiva estudantes com alto risco de evasão com base em métricas acadêmicas, financeiras e comportamentais agregadas.
- **Uso Secundário:** Fornecer suporte automatizado para que o agente de pendências e monitoramento dispare alertas precoces e recomendações de intervenção pedagógica ou financeira.
- **Usuários Altedidos:** Gestores acadêmicos, orientadores educacionais e o próprio sistema automatizado de atendimento ao aluno.

Dados de Treinamento

- Base de dados unificada institucional contendo 12.842 registros de alunos, integrando dados de histórico, matrículas, financeiro, contato e relacionamentos institucionais.

Métricas de Desempenho (Avaliação)

- O modelo principal (*Random Forest*) atinge **90.93% de acurácia** e **0.9321 de ROC-AUC** no conjunto de teste independente, superando com folga os critérios mínimos da baseline linear.

Limitações Conhecidas

1. **Sensibilidade a Mudanças no Perfil:** O modelo reflete padrões históricos de evasão e pode apresentar viés caso ocorram mudanças abruptas na política institucional ou socioeconômica.
2. **Falta de Contexto Qualitativo:** Variáveis textuais livres ou nuances emocionais do aluno não são capturadas diretamente pelas features tabulares atuais.
3. **Natureza Probabilística:** As saídas indicam riscos estatísticos e podem gerar falsos positivos, exigindo validação humana antes de medidas drásticas.

Diretrizes Éticas e Governança

- **Privacidade:** Os dados dos alunos devem ser tratados em conformidade com as leis de proteção de dados (como a LGPD), garantindo anonimização em relatórios públicos.
- **Transparência:** O uso de pontuações de risco deve servir exclusivamente para apoio e suporte ao estudante, evitando punições automáticas sem revisão humana.